

Python 人工智能实践项目选题报告——垃圾短信智能检测

课程名称	Python 人工智能程序设计实践	提交日期	2026 年 4 月 15 日
项目名称	垃圾短信智能检测	团队成员	杨萱昱、方余文星、曾欣语、刘馨喻

一、项目简介

随着移动通信普及，骚扰与诈骗短信泛滥。本项目基于机器学习算法，构建一个高效、可解释的垃圾短信分类器，旨在保护用户信息安全，减少骚扰信息带来的损失。

二、数据来源与描述

本项目采用公开数据集 SMS Spam Collection Dataset，该数据集广泛应用于文本分类和垃圾短信检测研究，具有较高的权威性和代表性。数据由 Tiago A. Almeida 和 José María Gómez Hidalgo 收集整理，来源包括 Grumbletext Web 论坛、NUS SMS Corpus 以及真实用户短信数据。数据获取来源如下：

Kaggle 镜像链接：<https://www.kaggle.com/datasets/uciml/sms-spam-collection-dataset>

GitHub：<https://github.com/AYUSHSURYAVANSHI/SMS-Spam-Collection-NLP-Project>

阿里云天池（备选）：<https://tianchi.aliyun.com/dataset/187549>

该数据集为 CSV 格式，共包含两列字段：label 与 message。其中 label 表示短信类别（ham 表示正常短信，spam 表示垃圾短信），message 表示短信原始文本内容。

数据集共包含 5574 条短信记录，其中正常短信 4825 条，垃圾短信 747 条，类别比例约为 6.46:1，存在明显类别不平衡问题。因此，在模型评估阶段将重点关注 F1-score 指标，并考虑采用过采样或欠采样等方法改善类别不平衡问题。

从文本特征来看，正常短信通常较短，多为日常交流内容，例如“Ok”、“Call me”；而垃圾短信通常长度较长，包含电话号码、网址链接及金额信息等关键词，例如“WINNER!!”、“Call 0906…”等，这为后续文本分类任务提供了良好的区分依据。

三、初步模型思路

本项目将垃圾短信识别问题建模为二分类问题，并按照“数据清洗—特征表示—模型训练—性能评估”的流程进行实现。

首先对短信文本进行预处理，包括大小写统一、去除特殊符号、去除停用词及分词处理等步骤，以减少无关信息对模型训练的干扰。随后采用 TF-IDF 方法将文本转换为向量表示，并尝试不同 n-gram 特征以提高模型表达能力。

在模型选择方面，首先采用 Multinomial Naive Bayes 作为基线模型，并进一步引入 Logistic Regression 与 Linear SVM 等经典机器学习算法进行对比实验，分析不同模型在垃圾短信分类任务中的性能差异。

模型评估指标包括 Accuracy、Precision、Recall 与 F1-score，其中重点关注 F1-score，以应对类别不平衡问题。同时通过 GridSearchCV 进行参数调优，并对误判样本进行分析，总结模型不足并提出改进方向。

四、参考代码与文献

本项目参考了自然语言处理领域中垃圾短信分类的经典研究与工程实践，主要包括以下文献与开源代码：

（1）数据集原始论文：Almeida T A, Gómez Hidalgo J M, Yamakami A. Contributions to the Study of SMS Spam Filtering: New Collection and Results. ACM Symposium on Document Engineering, 2011.

链接：<https://dl.acm.org/doi/10.1145/2034691.2034742>

（2）机器学习方法研究：Shirani-Mehr H. SMS Spam Detection using Machine Learning Approach. Stanford CS229, 2013.

链接：[Stanford CS229 论文全文 \(PDF\)](#)

（3）深度学习扩展研究：Gupta J, et al. SMS Spam Detection using Machine Learning and Deep Learning Techniques. IEEE Conference, 2021.

链接：[IEEE Xplore 官方链接](#)

（4）参考开源代码：GitHub 工程化项目：[SMS-Spam-Collection-NLP-Project](#)

CSDN 详细教程代码：[机器学习之基于文本内容的垃圾短信识别](#)

五、团队分工

杨萱昱（组长）	模型优化与对比实验	在基线模型基础上构建 SVM 等模型，并利用 GridSearchCV 进行参数调优，对不同模型性能进行对比分析，同时开展误判样本分析并提出改进方向。
方余文星	数据获取清洗与 EDA 分析	公开垃圾短信数据集的下载与整理，完成数据去重、缺失值处理及标签统一等清洗工作，并进行探索性数据分析，绘制类别分布、文本长度与词云等可视化图表。
曾欣语	特征工程与基线模型	文本分词与停用词处理，采用 TF-IDF 进行特征提取，并构建 Naive Bayes 与 Logistic Regression 等基线模型，完成训练集划分，输出训练日志与初步评估结果。
刘馨喻	技术报告与汇报展示	负责整理技术报告与实验结果，制作项目汇报 PPT，并根据项目进展开发简单 Demo（如 Streamlit 或 Gradio），完成项目展示与答辩准备。