

基于机器学习的垃圾短信智能检测中期进展报告

一、项目简介与目标

本项目旨在利用 Python 及 NLP 技术构建垃圾短信智能识别系统。项目确立了以数据驱动为核心的研发思路，目前已基于 SMS Spam Collection 数据集完成了全流程流水线开发：通过正则表达式构建了稳健的自动化清洗程序；利用 EDA 技术量化了垃圾短信统计特征；并跑通了朴素贝叶斯（NB）与逻辑回归（LR）基线模型，建立完善的性能评估基准，为后期深度调优奠定坚实基础。

二、数据处理细节与 EDA 统计

2.1 自动化清洗流水线与样本对齐

数据质量直接决定了机器学习模型的上限。团队开发的 `clean_data.py` 实现了一套标准化的清洗流程。我们不仅进行了常规的缺失值检测与处理，还针对短文本特点实施了以下策略：


2.2.1 噪声精准剔除:

利用正则表达式识别并移除 URL 链接、电子邮箱地址以及非字母的特殊符号。

2.2.2 文本标准化：执行了全员小写化处理，并压缩了冗余空格。

2.2.3 去重优化: 原始记录共 5,574 条, 经清洗去重后保留 5,169 条有效记录。

2.2 探索性数据分析 (EDA) 小结




图表 1 样本类别分布图

通过可视化分析，我们得到了关于数据的三大核心认知：

2.2.1 类别不平衡显著：正常短信（Ham）占比 87.4%，而垃圾短信（Spam）仅占 12.6%，比例约为 6.9:1。这提示我们在模型评价时不能盲目追求准确率，必须引入 F1-score 等综合指标。

2.2.2 长度特征具备区分度：如图表 2 分析显示，垃圾短信的长度分布明显较长，均值显著高于正常短信，这证明文本长度可作为分类的辅助逻辑。

2.2.3 关键词特征差异化: 词云图显示, 垃圾短信高频词集中在营销词汇, 而正常短信则多为日常交流词汇, 这验证了 TF-IDF 特征表示法的有效性。



Message Length (characters)

图表 2 短信长度分布对比



图表 3 正常短信（左）与垃圾短信（右）词云图对比

三、 特征工程与基线模型设计思路

3.1 文本表示方案

为了将非结构化的文本转化为模型可运算的数值矩阵，我们采用了 TF-IDF（词频-逆文档频率）算法。在特征提取脚本 `extract_features.py` 中，我们加载了 NLTK 英文停用词表，过滤了 179 个无实际语义贡献的高频虚词。通过设置 `max_features=5000` 选取权重最高的特征，并利用 `min_df=2` 剔除极低频噪声。最终产生的 5000 维稀疏矩阵不仅保留了核心语义信息，还大幅提升了运算效率。

3.2 训练策略与模型选择

在数据集划分上，使用分层抽样策略，按照 8:2 的比例划分训练集（4,132 条）与测试集（1,034 条），确保两类样本在不同集合中的比例与原数据集保持一致。在模型选择上，构建了两套基线：
多项式朴素贝叶斯（MultinomialNB）：作为生成式模型的代表，用于建立性能底线。
逻辑回归（Logistic Regression）：作为判别式模型的代表，通过设置 `class_weight='balanced'` 参数，手动提升少数类（Spam）在损失函数中的权重，以应对类别不平衡问题。


四、 基线模型效果评估与对比

4.1 实验结果量化对比

通过运行 `evaluate.py`，我们得到了基线模型的详细对比表。

模型名称	准确率 (Acc)	精确率 (Pre)	召回率 (Rec)	F1-Score
朴素贝叶斯(NB)	0.9574	1.0000	0.6641	0.7982
逻辑回归(LR)	0.9797	0.9044	0.9389	0.9213

4.2 性能深度分析



图表 4 朴素贝叶斯模型混淆矩阵

混淆矩阵显示，NB 模型表现出极高的“保守性”，误报率为零但漏报率较高（Recall 0.66）。相比之下，LR 模型在垃圾短信捕捉能力上表现优异，召回率高达 93.89%，F1 达 0.9213。

五、 遇到的问题及解决方案

在项目推进过程中，团队主要克服了以下技术瓶颈：

- 5.1 类别偏向问题：**初期模型倾向于将所有短信预测为正常短信以获取表面上的高准确率。我们通过引入分层抽样和调整逻辑回归的类权重参数，成功引导模型关注少数类特征。
- 5.2 特征空间过载：**5000 维特征在普通内存下运算较慢。我们采用了稀疏矩阵格式进行存储与运算，将计算资源消耗降低了约 70%。
- 5.3 清洗逻辑的鲁棒性：**部分短信在清洗后变成了空字符串。我们在流水线末端增加了空值过滤逻辑，确保输入模型的数据均为有效文本，保证了训练日志 `logs/nb.txt` 的准确性。